Attention одной головы

Позиции токенов в контексте

needle

…	…	Dolores	Park	…	…	…	?
0,05	0,05	0,35	0,40	0,03	0,02	0,06	0,04

Выделены вероятности, входящие в сумму.

Attention mass

Сумма вероятностей внимания
на позициях needle

$$m_t^{(h)} = \sum_{j \in N} A_{t,j}^{(h)}$$

$$S_{\text{mass}}^{(h)} = \frac{1}{|T_N|} \sum_{t \in T_N} m_t^{(h)}$$

N — диапазон needle.
T_N — шаги, где выходной токен есть в needle.

Retrieval Score · multiset

Argmax — на «Park» внутри needle:
+1 hit, если квота токена не исчерпана.

$$S_{\text{RS}}^{(h)} = \frac{\sum_v \min(H_h(v),\, C_N(v))}{|N|}$$

H_h(v) — совпавшие argmax-hit.
C_N(v) — число вхождений токена в needle.

На этом шаге сгенерирован

токен «Park»