GLM-4.6V-Flash · top-40 → top-80 → top-100

top-40 · Token multiset
Средний recall: 84.0%

top-40 · Attention mass
Средний recall: 23.9%

top-40 · QRScore
Средний recall: 25.0%

top-80 · Token multiset
Средний recall: 45.8%

top-80 · Attention mass
Средний recall: 25.0%

top-80 · QRScore
Средний recall: 25.0%

top-100 · Token multiset
Средний recall: 25.1%

top-100 · Attention mass
Средний recall: 22.0%

top-100 · QRScore
Средний recall: 24.8%

Глубина иголки, %
0
11
22
33
44
56
67
78
89
100

Длина контекста, токенов
1 000
4 053
7 105
10 158
13 211
16 263
19 316
22 368
25 421
28 474
30 000

ROUGE-1 recall, %
100
75
50
25
0

Paul Graham / San Francisco · no thinking · 110 одинаковых prompts · baseline: 100% recall
Красный = низкое качество, зелёный = высокое · legacy_uniform masking при decode.