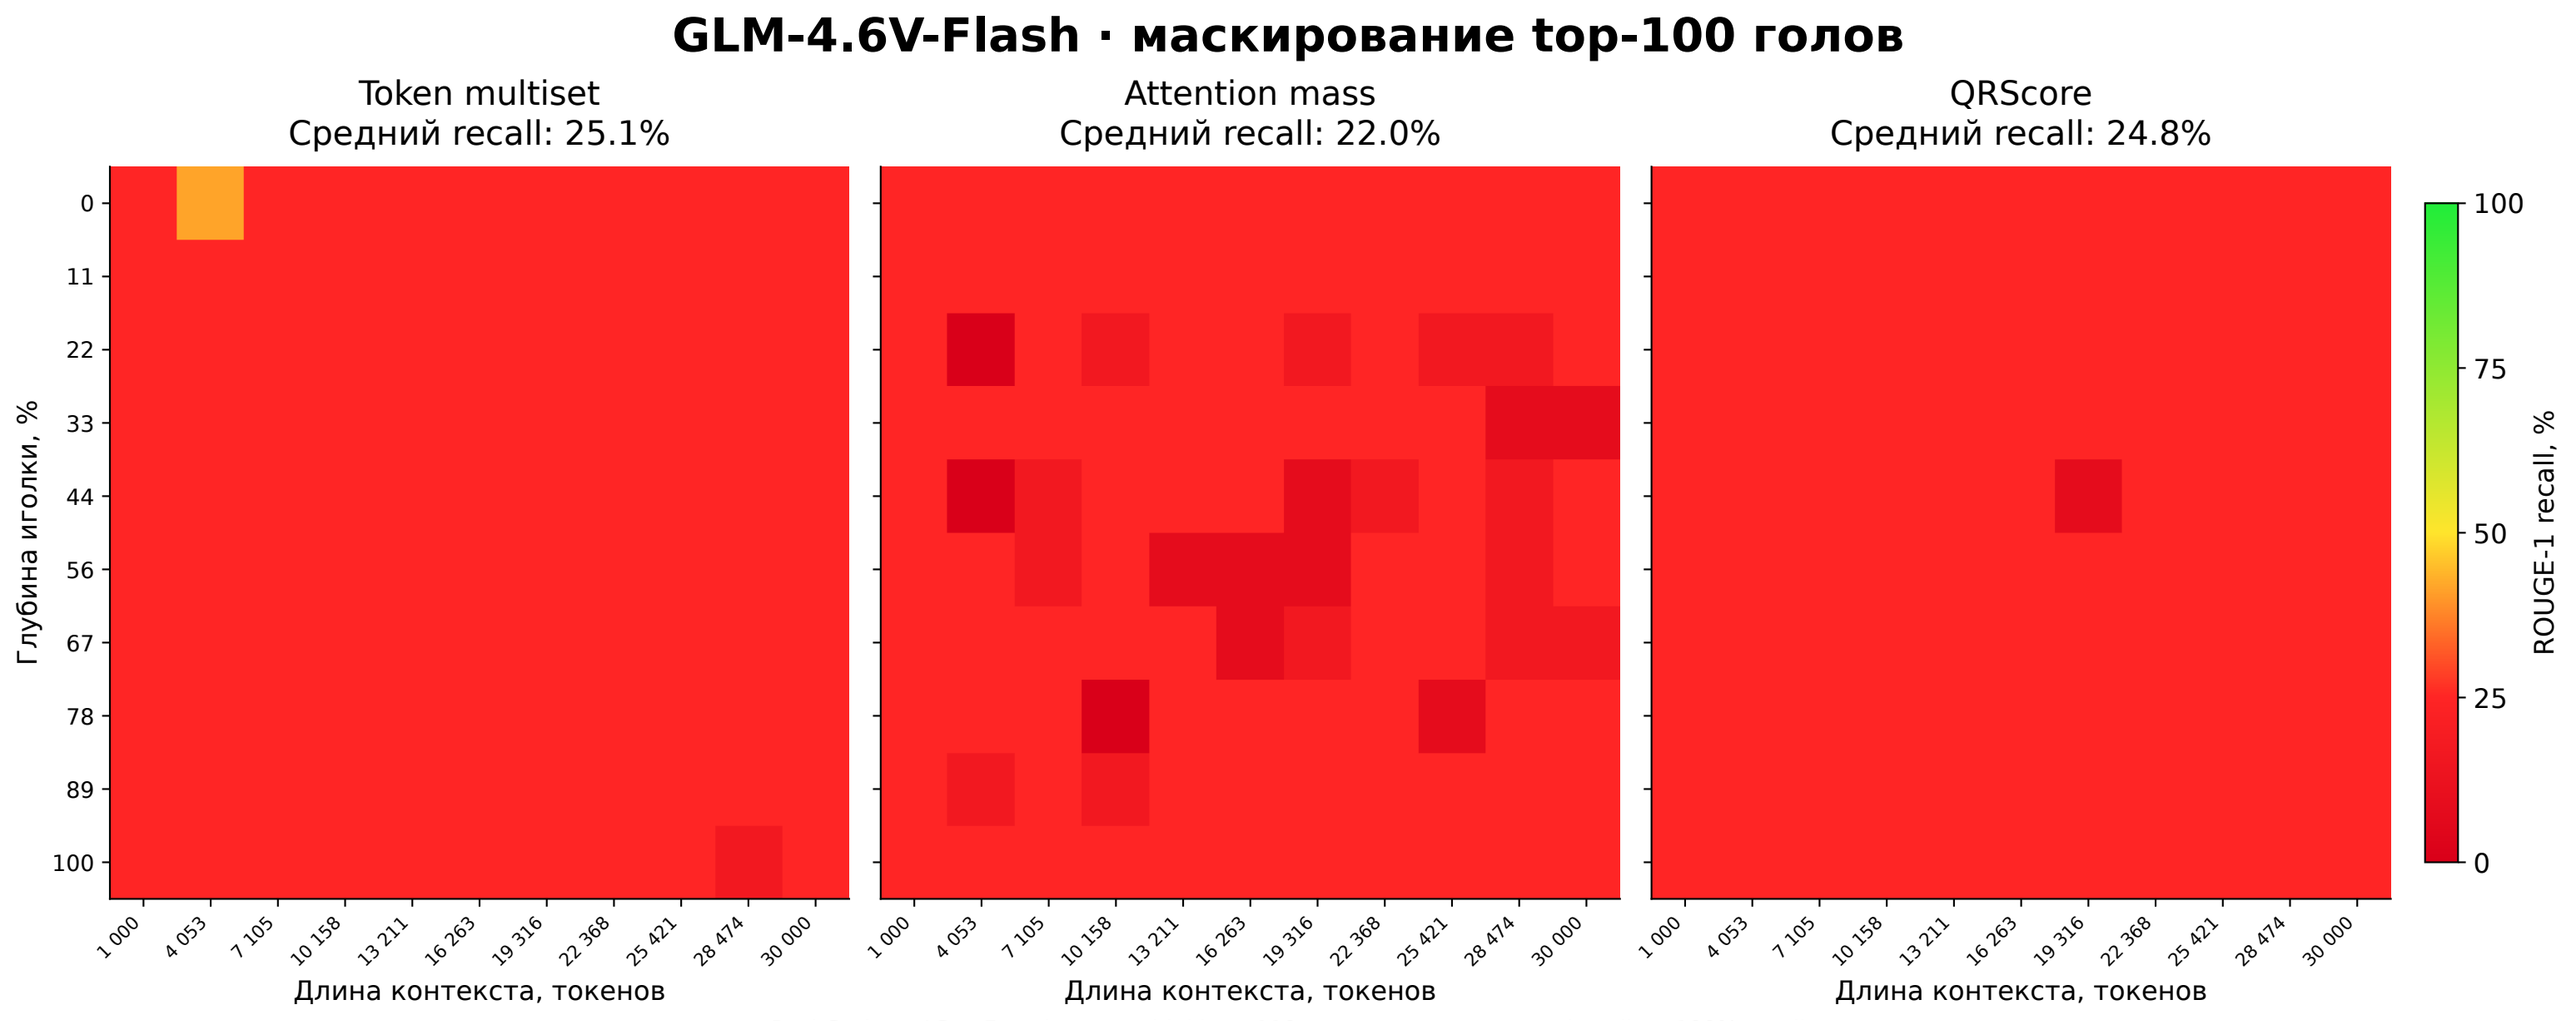
GLM-4.6V-Flash · маскирование top-100 голов
Token multiset
Средний recall: 25.1%
Attention mass
Средний recall: 22.0%
QRScore
Средний recall: 24.8%
Глубина иголки, %
0
11
22
33
44
56
67
78
89
100
1 000
4 053
7 105
10 158
13 211
16 263
19 316
22 368
25 421
28 474
30 000
Длина контекста, токенов
ROUGE-1 recall, %
100
75
50
25
0
Paul Graham / San Francisco · no thinking · 110 одинаковых prompts · baseline: 100% recall
Красный = низкое качество, зелёный = высокое · legacy_uniform masking при decode.